

Rechnerarchitektur

Vorlesung 14:x86 Architektur, Programmaufbau und einfache Instruktionen

Prof. Dr. Martin Mauve

Haben Sie noch Fragen zur letzten Vorlesung?

Thema: Caching. Details; Core i7, Einführung Assembler

Fahrplan



Einstie

Grundlagen der x86 Architektur

Programmaufbau eines Assemblerprogramms

Arithmetische und Logische Instruktionen

Verschiebungen und Rotationen

Sprünge und Schleifen

Der Stack

Funktioner

Von C zu Assembler

Buffer Overflow Exploits

Dynamische Speicherverwaltung

Grundlagen der x86 Architektur Rechnerarchitektur

Speicher

- x86-Prozessoren adressieren den Arbeitsspeicher byteweise.
- Instruktionen können auf einem oder mehreren Bytes im Arbeitsspeicher arbeiten.
- Je nach Anzahl der Bytes verwendet man bei x86-Prozessoren die folgenden Begriffe:
 - word = 2 Byte
 - double word = 4 byte
 - quad word = 8 byte
 - paragraph = 16 byte
- Die Bytereihenfolge der x86-Architektur ist Little Endian.

(niederwertigstes Byte wird zuerst, also an der niedrigsten Adresse gespeichert)

Grundlagen der x86 Architektur Rechnerarchitektuu

365

Speichermodelle

- Real Mode, Flat Model: ab Intel 8080
 - 64K für alles (Programm und Daten)
 - Betriebssysteme: CP/M-80, später DOS
- Real Mode, Segmented Model: ab Intel 8086
 - für die Kompatibilität mit 8080: Einteilung des Speichers in 64k Blöcke
 - Man muss manuell festlegen, welchen Block man gerade verwendet
 - sehr aufwändig und fehleranfällig
 - Betriebssysteme: DOS
- Protected Mode: ab Intel 80386
 - 4GB virtueller Speicher f
 ür alles (Programm und Daten)
 - Betriebssysteme: Windows, Linux
- Für die Vorlesung:
 - Protected Mode f
 ür Linux
 - Real Mode, Flat Model f
 ür DOS

Prozessor

- Der Prozessor stellt den Instruktionssatz zur Verfügung.
- Dieser Instruktionssatz unterscheidet sich i.d.R. von Prozessor zu Prozessor.
- Instruktionssatz wird durch die Mikroarchitektur/-programme implementiert.
- Wir verwenden hier den Instruktionssatz der Intel-x86-Familie:
 - wird auch IA-32 (Intel Architecture 32) genannt
 - ab 80386, auch entsprechende AMD-Prozessoren
 - Erweiterungen MMX, SSE,...
 - 32 Bit ist (hier) die natürliche Größe für Operanden und Adressen
 - inzwischen für alle aktuellen CPUs: 64-Bit-Erweiterungen (verwenden wir hier nicht)

Grundlagen der x86 Architektur Rechnerarchitektur

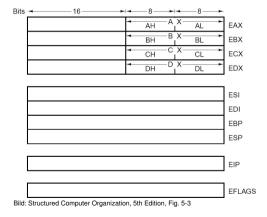
Register

- Innerhalb des Prozessors gibt es so genannte Register:
 - · dies sind Speicherzellen
 - auf die besonders schnell zugegriffen werden kann
 - die teilweise besondere Bedeutung bei verschiedenen Instruktionen haben
- Viele Operationen verwenden Register als Operanden oder zum Speichern des Ergebnisses.

Grundlagen der x86 Architektur Rechnerarchitektur

Register der IA-32-Architektur I

- Entwicklungsgeschichte (8086 von 1978!) kann aus dem Registersatz abgelesen werden
 - E = Extended = 32 Bit
- EAX, EBX, ECX, EDX
 - allgemeine 32-Bit-Register, aber:
 - EAX: Berechnungen
 - EBX: Zeiger (Pointer)
 - ECX: Schleifen
 - EDX: Mult/Div, 64 Bit mit EAX
 - 16- und 8-Bit-Teile (286, 8088)

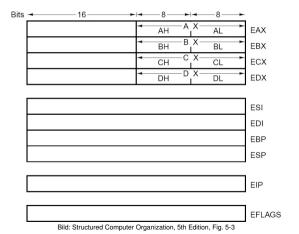


Grundlagen der x86 Architektur

Register der IA-32-Architektur II

- ESI, EDI: String-Operationen
- EBP, ESP: Base/Stack-Pointer
- CS-GS: Speicher-Segment-Zugriff (nicht dargestellt)
- EIP: Instruction Counter (=PC)
- EFLAGS: Prozessorstatuswort

370



Grundlagen der x86 Architektur Rechnerarchitektur

EFLAGS-Register

Das EFLAGS-Register hat eine besondere Bedeutung:

- Es aibt den Status des Prozessors an.
- Es erteilt Informationen über die letzte Berechnung.
- Jedes Bit in diesem Register hat eine eigene Bedeutung.
- Beispiele:
 - Sign Flag (S): Im Ergebnis der letzten Operation war das höchstwertige Bit gesetzt.
 - Zero Flag (Z): Das Ergebnis der letzten Operation war 0.
 - Carry Flag (C): Bei der letzten Operation gab es einen Übertrag.
 - Overflow Flag (O) Bei der letzten Operation gab es einen Überlauf.
- Die Flags des EFLAGS-Registers k\u00f6nnen mit speziellen Instruktionen abgefragt werden.
 - realisieren bedingter Sprünge

Rechnerarchitektuu

Fahrplan



Einstieg

Grundlagen der x86 Architektur

Programmaufbau eines Assemblerprogramms

Arithmetische und Logische Instruktionen

Verschiebungen und Rotationen

Sprünge und Schleifen

Der Stack

Funktioner

Von C zu Assembler

Buffer Overflow Exploits

Dynamische Speicherverwaltung

Programmaufbau bei Assembler (NASM)

- Ein Programm kann aus mehreren Übersetzungseinheiten bestehen.
- Eine Übersetzungseinheit wird Modul genannt.
- Ein Modul kann die folgenden Elemente beinhalten:
 - Segmentidentifikation
 - Assembler-Instruktionen
 - Pseudo-Instruktionen
 - Präprozessor-Anweisungen
 - Direktiven an den Assembler (beinhaltet Segmentidentifikation)
- Dies ist assemblerspezifisch (also hier für NASM), von den Grundzügen her aber typisch für x86-Assembler.

Segmentidentifikation

- Eine Übersetzungseinheit kann aus mehreren (Speicher-)Bereichen bestehen.
- Beispiele:
 - .text: In diesem Bereich befinden sich die ausführbaren Instruktionen.
 - .data: In diesem Bereich befinden sich "Variablen" mit vordefinierten Werten.
 - .bss (block start symbol): In diesem Bereich befinden sich "Variablen", die keinen vordefinierten Wert besitzen.
- Diese Bereiche nennt man Segmente oder Sektionen.
- Der Beginn eines Segmentes wird mit der Assembler-Direktive SEGMENT (oder wahlweise SECTION) gekennzeichnet.
- Beispiel:

```
%include "asm_io.inc"
segment .text
      global asm_main
asm_main:
    enter 0,0 ; Funktionseintritt
    ...
```

Assembler-Instruktion I

- Assembler-Instruktionen werden vom Assembler in Instruktionen des Befehlssatzes des Prozessors übersetzt.
- In NASM haben Assembler-Instruktionen folgendes Format:

```
<label>: <instruction> <operands> ; <comment>
```

Beispiel:

```
loop1: mov ebx, 1; Start of Loop, initialize ebx
```

label

375

- Damit kann diese Zeile identifiziert werden, ohne dass man mühsam die Speicheradresse dieser Zeile bestimmen muss:
 - Das Bestimmen der Speicheradresse übernimmt der Assembler für uns.
- Ein Label kann anstelle einer Adresse geschrieben werden, z.B.
 - um den Ort zu identifizieren, an dem Daten abgelegt sind
 - um Ziele von Verzweigungen oder Sprüngen zu identifizieren

Assembler-Instruktion II

- instruction
 - die eigentliche Assembler-Instruktion
- operands
 - Je nach Instruktion k\u00f6nnen Operanden folgen.
 - Operanden können
 - direkt angegeben werden (als Konstante)
 - · in einem Register stehen
 - im Speicher stehen
- comment
 - · alles nach dem ; wird ignoriert
- Zeilenverlängerung: Eine Assembler-Instruktion muss in einer Zeile stehen.
 - Verlängerung einer Zeile durch \ als abschließendes Zeichen möglich.
 - Dann wird der Zeilenumbruch ignoriert.

Spezifikation von Instruktionen

Auszug aus dem NASM-Handbuch:

```
MOV mem, reg8 [8086]
MOV reg16, reg16 [8086]
MOV mem, reg32 [386]
MOV reg8, imm [8086]
```

- Dies gibt an, welche Operanden erlaubt sind:
 - regX = Register der Größe X
 - mem = Speicher
 - imm = direkte Angabe des Operanden
 - ...

wobei hier 1. Operand das Ziel und 2. Operand die Quelle ist

Dann folgt der Prozessor, ab dem die Instruktion vorhanden ist.

Erlaubte Adressierung von Operanden

- Immediate: Operand als Konstante angeben
 - nur für Operanden, die kein Ziel für eine Operation sind
 - mov eax, 0
- Register: Register angeben
 - für Operanden, die Ziel oder Quelle für eine Operation sind
 - mov eax, ebx
- Speicher: Adresse der Speicherzelle in [] angeben
 - nur ein Operand darf direkt auf diese Art adressiert werden
 - mov eax, [esp]

Typische Addressierungsfehler

- mov 17, 1
 nur ein Operand darf Immediate adressiert werden
- mov 17, bx
 Ziel darf nicht Immediate adressiert werden
- mov cx, dh
 beide Operanden müssen die gleiche Größe haben
- mov [ax], [bx]
 nur ein Operand darf direkt im Speicher adressiert werden

Speicherzugriff

- Wenn ein Operand im Speicher steht, wird die Adresse des Operanden so angegeben: [Adresse]
- Beispiele ohne Speicherzugriff:

```
• mov eax, 1 ; lädt eine 1 in das Register eax
```

- Sei loop1 ein label, dann mov eax, loop1; lädt die Adresse (!) von loop1 in eax
- Beispiele mit Speicherzugriff:
 - Sei buffer ein label, dann

```
mov eax, [buffer] ; lädt 4 Bytes aus dem Speicher beginnend \ mit dem Byte an der Speicherstelle buffer
```

- mov eax, [ecx+ebx*4+0x800]; lädt 4 Bytes aus dem Speicher \
 beginnend mit dem Byte an der \
 Speicherstelle ecx+ebx*4+0x800
 - Dieses Konstrukt benötigt man z.B. um effizient über ein Array iterieren zu können

Speicheradressierung

erlaubte Adressierung: [BASE+(INDEX*SCALE)+DISP]

- BASE: EAX, EBX, ECX, EDX + deren verkürzte Varianten
 - z.B.: Adresse des ersten Wertes in einem Array
- INDEX: EAX, EBX, ECX, EDX + deren verkürzte Varianten
 - z.B.: Index eines Array Elementes
- SCALE: 1, 2, 4 oder 8
 - z.B.: Größe eines Array Elementes
- DISP: 32-Bit Konstante
 - z.B. um einen konstanten Offset in eine Tabelle zu addieren
- Alle Elemente sind optional.

Datentypen

- In Assembler ist der Datentyp eines Operanden seine Länge in Bytes.
- Hat eine Instruktion mehr als einen Operanden, dann muss die Länge der Operanden meist identisch sein:
 - mov eax, ebx ist korrekt
 - mov eax, bx ist nicht korrekt
- Die Länge eines Operanden kann implizit bekannt sein:
 - z.B. bei mov eax, 0x10 wird 0x10 als 32-Bit Zahl interpretiert
- Eine explizite Angabe der Länge eines Operanden ist erforderlich, wenn sie implizit nicht bestimmt werden kann:
 - z.B. beineg byte [wert]
 - erlaubte Typangaben: byte, word, dword

Pseudoinstruktionen

- Pseudoinstruktionen werden nicht direkt in Instruktionen des Befehlssatzes übersetzt
- Sie haben aber das gleiche Format wie Assembler-Instruktionen
- Man verwendet Pseudoinstruktionen zum Beispiel für
 - das Bereitstellen von initialisiertem Speicherplatz (meist im .data Segment):
 - db 0x55; Speicherplatz der Größe 1 Byte belegt mit 0x55
 - db 0x55, 0x56, 0x57; drei aufeinander folgende Bytes
 - db 'hello',13,10,'\$' ; 8 aufeinander folgende Bytes
 - dw 0x1234 ; 0x34 0x12 (little endian)

 - dw 'abc'; 0x61 0x62 0x63 0x00 (Auffüllen auf Wort Grenzen)
 - dd 0x12345678 ; 0x78 0x56 0x34 0x12 (little endian)
 - das Bereitstellen von uninitialisiertem Speicherplatz (meist im .bss Segment):
 - buffer: resb 64 : 64 * 1 Byte reserviert

Konstanten I

- In NASM gibt es 4 verschiedene Arten von Konstanten:
 - numeric, character, string, (floating-point)
- numeric (überall, wo die direkte Angabe eines Operanden erlaubt ist):
 - standard: dezimal (mov ax, 100)
 - hexadezimal durch
 - den Präfix 0x (Beispiel: mov ax, 0xa0)
 - den Suffix h (Beispiel: mov ax, 0a0h)
 Achtung! die Zahl muss mit einer Ziffer beginnen, daher die '0'
 - den Präfix \$ (Beispiel: mov ax, \$0a0)
 Achtung! die Zahl muss mit einer Ziffer beginnen, daher die '0'
 - oktal durch q oder o als Suffix
 - mov ax, 777q
 - mov ax, 777o
 - binär durch b als Suffix (mov ax, 10010011b)

Konstanten II

- character (überall, wo die direkte Angabe eines Operanden erlaubt ist):
 - bis zu 4 Zeichen in einfachen oder doppelten Anführungszeichen
 - Little Endian wird berücksichtigt:

```
mov eax, 'abcd'; danach steht 0x64636261 in eax
```

- string (nur bei den Pseudoinstruktionen DB/DW/DD und INCBIN):
 - beliebig lange Kette von Zeichen in einfachen oder doppelten Anführungszeichen
 - es wird immer auf die "richtige" Größe aufgefüllt
 - DB=ein Byte, DW=zwei Byte, DD=vier Byte
 - die Reihenfolge im Speicher ist so wie angegeben
 - db 'hello' ; ist äquivalent zu
 - db 'h','e','l','l','o'
 - dd 'ninechars'; ist äquivalent zu
 - dd 'ninechars',0,0,0

Beispiel: Addieren von zwei Zahlen

```
%include "asm io.inc"
segment .data
wert1: dd 0x20
wert 2 ·
        dd 0x40
segment .bss
resultat: resd 1
segment .text
       global
              asm main
asm main:
              0.0
                             : Funktion initialisieren
       enter
       pusha
       mov eax, [wert1] ; Ersten Operanden laden
       add eax, [wert2] ; Zweiten Operanden hinzuaddieren
       mov [resultat], eax
                             ; Ergebnis speichern
       dump_regs 1
                             ; Ausgabe der Registerwerte
                             ; zu C zurückkehren
       popa
       mov
               eax, 0
       leave
       ret
```

Addieren von zwei Zahlen – Resultat

```
Register Dump # 1

EAX = 00000060 EBX = 40155B90 ECX = 00000001 EDX = 401570C0

ESI = 40014020 EDI = BFFFEBB4 EBP = BFFFEB58 ESP = BFFFEB38

EIP = 08048425 FLAGS = 0206
```

Der Präprozessor

- Analog zu C unterstützt auch NASM einen Präprozessor
- Dieser wird vor dem eigentlichen Übersetzen ausgeführt
- Anweisungen an den Präprozessor sind mit % gekennzeichnet
- Beispiel: %include "asm_io.inc"
 - fügt den Inhalt der Datei asm_io.inc an diese Stelle ein
- sehr mächtig:
 - genaueres im NASM-Handbuch (Kapitel 4)